



Pontifícia Universidade Católica de Minas Gerais

DIRETORIA DE EDUCAÇÃO CONTINUADA - IEC

Disciplina: GERAÇÃO DE LINGUAGEM NATURAL E ENGENHARIA DE PROMPT

Nome do curso: IA GENERATIVA E APLICAÇÕES COM LLMS

Professor: Ricardo Brito Alves

Trabalho: Estudo Comparativo de Modelos e Prompts

Grupo: Dayvson Pellegrino Rodrigues, Denilson Bremer Procopio Ribeiro e Leonardo Mello Ragagnin



Caderno de Trabalhos

Projeto incremental: desenvolvimento de um Copiloto Inteligente Corporativo

Os seis trabalhos formam uma única trajetória de projeto. Cada entrega deve reaproveitar, revisar e ampliar os artefatos produzidos anteriormente. O grupo deverá manter uma pasta ou repositório único com versões, evidências, decisões e resultados.

Regra de continuidade: o caso de uso corporativo escolhido no Trabalho 2 será mantido até o Trabalho 6. Mudanças de tema deverão ser justificadas e aprovadas pelo professor.

Visão geral das entregas

Aula	Trabalho	Produto incorporado ao projeto	Valor
1	Estudo Comparativo de Modelos e Prompts	Modelo e estratégia inicial selecionados	15
2	Especificação do Copiloto e Baseline	Escopo, requisitos, métricas e referência inicial	15
3	Biblioteca Versionada de Prompts	Prompts reutilizáveis e rastreáveis	15
4	Fluxo de Geração e Protótipo Textual	Fluxo integrado e protótipo textual	15
5	Protótipo Multimodal e Plano de Avaliação	Nova modalidade, testes e rubrica	20
6	Copiloto Inteligente Corporativo	Solução consolidada, demonstrada e avaliada	20



Trabalho 1 — Estudo Comparativo de Modelos e Prompts

Contexto

Antes de definir o Copiloto Inteligente Corporativo, o grupo deverá comparar modelos de linguagem em condições controladas. O objetivo é substituir escolhas baseadas apenas em preferência por uma decisão sustentada por critérios, evidências e adequação ao futuro caso de uso.

Objetivo

Comparar pelo menos três modelos de linguagem em tarefas equivalentes de geração textual, utilizando o mesmo conjunto de prompts, parâmetros registrados e critérios de avaliação. Ao final, recomendar um modelo principal e uma alternativa de contingência.

Requisitos

- Selecionar no mínimo três modelos, sendo permitidos modelos comerciais, gratuitos ou locais.
- Executar no mínimo quatro tarefas: resumo, reescrita, extração/classificação e geração orientada a um público.
- Usar os mesmos prompts, dados de entrada e critérios em todos os modelos.
- Registrar modelo/versão, data, parâmetros, latência percebida, quantidade de tokens quando disponível e custo estimado.
- Não utilizar dados pessoais, sigilosos ou protegidos nos testes.

Parte 01 — Definição do experimento

O grupo deverá formular a pergunta de comparação, selecionar os modelos, descrever as tarefas e definir previamente os critérios de qualidade.

Campo	Preenchimento obrigatório
Pergunta	Qual modelo e configuração atendem melhor ao projeto pretendido?
Modelos	Nome, fornecedor, versão e forma de acesso
Tarefas	Objetivo, entrada e saída esperada de cada teste
Parâmetros	Temperatura, top-p, limite de tokens e demais configurações
Crítérios	Correção, relevância, clareza, completude, aderência ao formato e segurança

Parte 02 — Conjunto controlado de prompts

Criar ao menos quatro prompts idênticos para todos os modelos. Cada prompt deve conter objetivo, contexto mínimo, instrução, restrições e formato de saída. Os textos de entrada devem ser anexados à entrega.

Parte 03 — Execução e registro

Executar cada combinação modelo × prompt sem alterar silenciosamente as instruções. Caso seja necessária nova tentativa, manter o resultado anterior e registrar o motivo da repetição.

Modelo	Tarefa	Parâmetros	Resultado	Latência/custo	Observações
Modelo A	P1 - Resumo	Não disponíveis	A1 - Sao10K Llama 3 8B Lunaris.docx	16 s / US\$ 0,000028	Boa síntese; termo inadequado: oficina.



Modelo B	P1 - Resumo	Não disponíveis	B1 - AionLabs Aion-RP 1.0.docx	6 s / US\$ 0,000822	Fiel, mas excede 130 palavras. Cumpre conteúdo, tamanho e formato.
Modelo C	P1 - Resumo	Não disponíveis	C1 - Mistral Large.docx	6 s / US\$ 0,002066	

Parte 04 — Avaliação e recomendação

Avaliar as respostas em escala de 1 a 5, justificar notas relevantes e elaborar uma síntese que explicita qualidade, limitações, custo, riscos e adequação ao caso de uso. A recomendação não deve se limitar à soma das notas.

Entregáveis e evidências

- Relatório em PDF ou documento equivalente, com método, resultados e recomendação.
- Planilha ou tabela completa do experimento.
- Prompts, entradas e saídas brutas identificadas.
- Registro de custos e limitações observadas.
- Apresentação breve da escolha e de suas ressalvas.



Laboratório Guiado — Como resolver o Trabalho 1

Estudo Comparativo de Modelos e Prompts

Resultado do laboratório: ao concluir, o grupo terá executado 12 testes controlados, calculado as notas comparativas, registrado latência e custo, escolhido um modelo principal e preparado todos os materiais solicitados no trabalho.

Roteiro e duração

Etapas	Atividade
1	Preparar pasta, equipe e ferramentas
2	Selecionar e registrar os três modelos
3	Ler o caso e organizar os dados de entrada
4	Revisar os quatro prompts controlados
5	Executar as 12 combinações em paralelo
6	Avaliar as respostas com a rubrica
7	Consolidar latência, custo e notas
8	Recomendar os modelos
9	Conferir e organizar a entrega

Tempo total estimado: 60 minutos. Para cumprir o tempo, o grupo deverá abrir previamente as três ferramentas e executar os testes em paralelo. Todos participam da recomendação final.

Organização expressa: o roteiro considera um grupo com pelo menos três integrantes, cada um responsável pela execução em um modelo. Em grupos menores, duplique as janelas de trabalho e mantenha o cronômetro da atividade.

Caso utilizado no laboratório

Para que todos os modelos recebam exatamente a mesma informação, use o texto corporativo fictício abaixo. Não acrescente informações externas durante a execução.

TEXTO-BASE — Política-piloto de trabalho híbrido

A empresa fictícia Aurora Tech adotará uma política-piloto de trabalho híbrido entre 1º de setembro e 30 de novembro. Colaboradores elegíveis poderão trabalhar remotamente até dois dias por semana, definidos com o gestor. As equipes deverão manter presença comum às terças-feiras para reuniões e atividades colaborativas. O benefício não se aplica a funções que dependam de atendimento presencial, operação de laboratório ou manutenção física. Exceções deverão ser aprovadas pela diretoria da área e registradas pelo RH. O colaborador deverá manter disponibilidade entre 9h e 17h, utilizar autenticação multifator e acessar documentos corporativos somente por dispositivos gerenciados. Despesas de internet e energia não serão reembolsadas durante o piloto. Os gestores acompanharão prazo das entregas, qualidade, colaboração e satisfação da equipe. O RH aplicará uma pesquisa no início e no final do período. Incidentes de segurança deverão ser informados imediatamente ao Service Desk. Ao término do piloto, a diretoria decidirá se a política será mantida, alterada ou encerrada. Dúvidas devem ser encaminhadas ao canal interno RH Responde.

Passo 1 — Preparar o ambiente do experimento

Crie uma pasta compartilhada ou repositório com a estrutura abaixo. Não salve apenas capturas de tela: mantenha também os textos copiáveis.

- 01_planejamento — pergunta, modelos, parâmetros e rubrica.
- 02_prompts — versões exatas dos quatro prompts.
- 03_entradas — texto-base e demais arquivos utilizados.
- 04_saidas_brutas — uma pasta por modelo, com quatro respostas.
- 05_avaliacao — planilha de notas, latência, tokens e custos.
- 06_relatorio — relatório final e apresentação.

Distribuição sugerida de papéis:

- Operador: executa os prompts sem modificá-los.
- Registrador: salva parâmetros, horários, respostas e evidências.
- Avaliadores: atribuem notas individualmente antes da discussão.
- Revisor: verifica consistência, cálculos e qualidade do relatório.

Checkpoint — avance somente se:

- ☐ A pasta possui as seis áreas.
- ☐ Os papéis foram definidos.
- ☐ Nenhum dado pessoal ou sigiloso será usado.

Registro do Passo 1: o grupo é formado por Dayvson, Denilson e Leonardo. Os testes utilizaram apenas o caso fictício Aurora Tech. A divisão nominal dos papéis e a estrutura de seis subpastas não foram registradas no documento.

Passo 2 — Selecionar e identificar os modelos

Escolha três modelos disponíveis ao grupo. Podem ser usados serviços web, APIs ou modelos locais. Registre a identificação exibida pela ferramenta; não escreva apenas o nome genérico do produto.

Código	Modelo/versão	Fornecedor	Acesso	Data/hora	Parâmetros disponíveis
A	Sao10K/L3-Lunar is-8B Llama 3 8B Lunar is	Sao10K via OpenRouter https://openrouter.ai/sao10k/l3-lunar-is-8b	OpenRouter (Web)	Data não registrada 14:02-14:54	Não disponíveis na interface; sessão nova por prompt
B	AionLabs/Aion-RP-Llama-3.1-8B Aion-RP 1.0	AionLabs via OpenRouter https://openrouter.ai/aion-labs/aion-rp-llama-3.1-8b	OpenRouter (Web)	Data não registrada 14:05-14:56	Não disponíveis na interface; sessão nova por prompt
C	Mistral Large	Mistral AI via OpenRouter https://openrouter.ai/mistralai/mistral-large	OpenRouter (Web)	Data não registrada 14:07-14:57	Não disponíveis na interface; sessão nova por prompt

Configuração recomendada para comparação:

- Temperatura: 0,2, quando configurável.
- Top-p: 1,0 ou valor padrão, sem combinar ajustes desnecessários.
- Limite de saída: 600 tokens ou equivalente.
- Uma nova conversa/sessão para cada prompt, evitando contaminação pelo histórico.
- Uma execução por combinação. Se repetir, preserve a primeira e justifique.

Se a interface não mostrar parâmetros: registre “não disponível na interface” e mantenha as demais condições iguais. Não invente valores.

Checkpoint — avance somente se:

- ☐ Há três modelos identificados por versão ou data.
- ☐ A forma de acesso foi registrada.
- ☐ As configurações comuns foram definidas antes dos testes.

Registro do Passo 2: os modelos A, B e C foram identificados pelas rotas exibidas no OpenRouter. A data do teste e os valores de temperatura, top-p e limite de saída não estavam disponíveis nos arquivos e foram marcados como não registrados.



Passo 3 — Preparar as entradas e a regra de controle

Copie o texto-base para um arquivo chamado texto_base.txt. Calcule ou registre seu tamanho aproximado e confirme que o mesmo conteúdo será colado em todos os modelos.

Regras do experimento:

- Não explicar o prompt ao modelo antes de executá-lo.
- Não pedir uma segunda resposta apenas porque a primeira pareceu fraca.
- Não corrigir manualmente a saída bruta.
- Não alterar o texto-base, a ordem das instruções ou o formato exigido entre modelos.
- Registrar qualquer bloqueio, erro, recusa ou truncamento como resultado válido do experimento.

Checkpoint — avance somente se:

- ☐ O texto-base foi salvo uma única vez.
- ☐ Todos concordaram com as regras de controle.

Registro do Passo 3: o mesmo texto-base fictício, com aproximadamente 165 palavras e 1.142 caracteres, aparece nas 12 execuções. Não foram encontrados dados pessoais, sigilosos ou protegidos.

Passo 4 — Revisar os quatro prompts controlados

Use os prompts abaixo sem alterar o conteúdo entre modelos. Substitua apenas o marcador [TEXTO-BASE] pelo caso fornecido.

PROMPT P1 — Resumo executivo

TAREFA: produzir um resumo executivo.

CONTEXTO: você apoia uma diretoria que precisa compreender rapidamente uma política interna.

INSTRUÇÕES:

1. Use somente informações do texto fornecido.
2. Produza de 100 a 130 palavras.
3. Destaque objetivo, período, elegibilidade, regras, controles e forma de avaliação.
4. Não invente justificativas, benefícios ou exceções.

FORMATO: um título e um único parágrafo.

TEXTO:

[TEXTO-BASE]

PROMPT P2 — Comunicado

TAREFA: reescrever a política como comunicado aos colaboradores.

PÚBLICO: profissionais da empresa com diferentes níveis de conhecimento técnico.

INSTRUÇÕES:

1. Use linguagem clara, cordial e objetiva.
2. Preserve datas, condições, exceções e responsabilidades.
3. Organize em: assunto, abertura, regras principais em tópicos e canal para dúvidas.
4. Não inclua promessas ou regras ausentes no texto.

TEXTO:

[TEXTO-BASE]

PROMPT P3 — Extração em JSON

TAREFA: extrair informações estruturadas da política.

INSTRUÇÕES:

1. Use somente o texto fornecido.
2. Se uma informação não existir, use null.
3. Retorne JSON válido, sem comentários antes ou depois.
4. Use exatamente as chaves abaixo.

FORMATO:

{

```
"periodo_inicio": "AAAA-MM-DD ou null",
"periodo_fim": "AAAA-MM-DD ou null",
"dias_remos_maximo": 0,
"dia_presencial_comum": "",
"horario_disponibilidade": "",
"funcoes_nao_elegiveis": [],
"controles_seguranca": [],
"canal_duvidas": ""
}
```

TEXTO:
[TEXTO-BASE]

PROMPT P4 — FAQ para gestores

TAREFA: criar uma FAQ para gestores sobre a política-piloto.

INSTRUÇÕES:

1. Crie exatamente 6 perguntas e respostas.
 2. Cubra elegibilidade, definição dos dias, presença comum, exceções, acompanhamento e segurança.
 3. Cada resposta deve ter no máximo 45 palavras.
 4. Use somente o texto fornecido.
 5. Quando a política não trazer detalhe suficiente, declare que o gestor deve consultar o RH Responde.
- FORMATO: numere de 1 a 6 e use "Pergunta:" e "Resposta:".

TEXTO:
[TEXTO-BASE]

Checkpoint — avance somente se:

- ☐ Existem quatro arquivos de prompt separados.
- ☐ O marcador será substituído sem outras alterações.
- ☐ Os formatos esperados são verificáveis.

Registro do Passo 4: os quatro prompts controlados P1, P2, P3 e P4 foram preservados nas três séries de resultados. A única substituição foi a inserção do mesmo texto-base.

Passo 5 — Executar as 12 combinações em paralelo

Distribua um modelo para cada integrante. Todos iniciam ao mesmo tempo e executam P1, P2, P3 e P4 no modelo recebido. Use sempre uma sessão nova. Antes de enviar, inicie um cronômetro; pare quando a resposta estiver completa. Salve a saída exatamente como recebida.

Meta de ritmo: reserve aproximadamente quatro minutos por prompt, incluindo execução e salvamento. O registrador acompanha a tabela geral e sinaliza quando faltarem cinco minutos.

Execução	Modelo	Prompt	Início	Latência (s)	Tokens	Arquivo da saída	Ocorrência
E01	A	P1	14:02	16s	214	A1 - Sao10K_Llama 3 8B Lunarís.docx	Terminologia inadequada: oficina.
E02	A	P2	14:14	06s	600	A2 - Sao10K_Llama 3 8B Lunarís.docx	Invenções de critérios, objetivos e regra.
E03	A	P3	14:20	07s	147	A3 - Sao10K_Llama 3 8B Lunarís .docx	JSON sem fechamento; ano assumido.



E04	A	P4	14:54	08s	243	A4 - Sao10K_Llama 3 8B Lunarix.docx	FAQ incompleta; idiomas mistos e invenções.
E05	B	P1	14:05	06s	302	B1 - AionLabs Aion-RP 1.0.docx	Excede o limite de 130 palavras.
E06	B	P2	14:15	12s	630	B2 - AionLabs Aion-RP 1.0.docx	Repete instruções e acrescenta conteúdo.
E07	B	P3	14:22	04s	159	B3 - AionLabs Aion-RP 1.0.docx	Canal de dúvidas incorreto; ano assumido.
E08	B	P4	14:56	08s	1k	B4 - AionLabs Aion-RP 1.0.docx	Invenções e respostas acima de 45 palavras.
E09	C	P1	14:07	06s	214	C1 - Mistral Large.docx	Sem ocorrência relevante.
E10	C	P2	14:17	07s	511	C2 - Mistral Large.docx	Objetivo inferido fora do texto-base.
E11	C	P3	14:24	03s	201	C3 - Mistral Large.docx	Ano de 2024 não informado no texto-base.
E12	C	P4	14:57	06s	347	C4 - Mistral Large.docx	Sem ocorrência relevante.

Nomeie as saídas de forma padronizada, por exemplo A_P1.txt. Se utilizar capturas de tela, use A_P1.png e mantenha também o arquivo textual.

Checkpoint — avance somente se:

- ☐ Há 12 saídas brutas identificadas.
- ☐ As latências foram registradas.
- ☐ Erros e repetições foram documentados.

Registro do Passo 5: as 12 saídas brutas estão identificadas. Não houve recusa nem repetição registrada; erros de conteúdo, formato e truncamento foram anotados na tabela de execuções.

Passo 6 — Avaliar as respostas

Divida a avaliação por tarefa, e não por modelo: um integrante compara P1 nos três modelos, outro compara P2 e assim sucessivamente. Dessa forma, cada avaliador aplica o mesmo padrão aos concorrentes. Registre notas rápidas e uma justificativa somente para falhas ou diferenças relevantes.

Rubrica de 1 a 5

Critério	Peso	Nota 1	Nota 3	Nota 5
Correção/fidelidade	25%	Erros ou invenções relevantes	Conteúdo correto com pequena imprecisão	Totalmente fiel ao texto
Relevância	20%	Desvia da tarefa	Atende o núcleo com excessos/omissões	Responde diretamente à tarefa

Clareza	15%	Difícil de compreender	Compreensível, mas irregular	Claro, organizado e adequado
Completude	15%	Faltam itens essenciais	Cobre a maior parte	Cobre todos os itens exigidos
Aderência ao formato	15%	Ignora o formato	Pequenos desvios	Cumpr integralmente
Segurança/limites	10%	Inventa ou excede o escopo	Risco menor ou ressalva incompleta	Não inventa e respeita limites

Notas 2 e 4 representam desempenhos intermediários entre os descritores.

Execução	Correção	Relevância	Clareza	Completude	Formato	Segurança	Nota ponderada	Justificativa
E01	4	5	4	4	5	4	4,35	Boa síntese, mas usa 'oficina' e omite parte das restrições.
E02	1	3	3	4	4	1	2,60	Inventa elegibilidade de 80%, objetivos e uma condição não prevista.
E03	3	5	4	5	1	2	3,45	Extraí os campos, mas assume 2023 e entrega JSON sem fechamento.
E04	1	2	2	1	1	1	1,35	Saída truncada: não completa seis respostas; inventa funções e mistura idiomas.
E05	5	5	5	5	3	5	4,70	Fiel e completo, porém ultrapassa o limite de 130 palavras.
E06	2	3	3	4	2	1	2,55	Repete instruções e acrescenta objetivos, regras e critérios ausentes.
E07	2	5	5	5	5	2	3,95	JSON válido; assume 2023 e troca RH
E08	1	3	3	5	1	1	2,30	Responde por Service Desk. Traz seis tópicos, mas excede 45 palavras e inventa várias informações.
E09	5	5	5	5	5	5	5,00	Cumpr integralmente o conteúdo, o limite e o formato solicitado.
E10	4	5	5	5	5	4	4,65	Comunicado claro e completo; infere um

Execução	Correção	Relevância	Clareza	Completeness	Formato	Segurança	Nota ponderada	Justificativa
E11	3	5	5	5	5	2	4,20	objetivo não expresso no texto-base. JSON válido e completo, mas inventa o ano 2024.
E12	4	5	5	5	3	4	4,35	Completo e conciso; falta numeração de 1 a 6 e há pequenas inferências.

Fórmula: nota ponderada = correção×0,25 + relevância×0,20 + clareza×0,15 + completude×0,15 + formato×0,15 + segurança×0,10. Para converter à escala 0–100, multiplique o resultado por 20.

Checkpoint — avance somente se:

- ☐ Todas as 12 execuções possuem seis notas.
- ☐ Notas extremas estão justificadas.
- ☐ Divergências entre avaliadores foram discutidas.

Registro do Passo 6: as notas foram consolidadas pela mesma rubrica para todas as tarefas. Notas baixas e desvios relevantes estão justificados na tabela.

Passo 7 — Consolidar custo, latência e notas | Tempo estimado: 4 min

Use o preço vigente informado pelo fornecedor na data do teste e registre a fonte e a data de consulta. Não compare apenas preços por milhão de tokens: calcule o custo real estimado das execuções.

FÓRMULA DE CUSTO

$\text{custo} = (\text{tokens_entrada} \div 1.000.000 \times \text{preço_entrada}) + (\text{tokens_saida} \div 1.000.000 \times \text{preço_saida})$

Fonte e método de custo: valores em dólares exibidos pela interface em cada uma das 12 saídas brutas. Os totais abaixo são a soma desses valores. A data de consulta e os preços unitários de entrada e saída não foram registrados, portanto não foram inventados.

Se a interface não informar tokens, registre “não disponível”. Opcionalmente, apresente uma estimativa claramente identificada como estimativa, informando a ferramenta ou método usado.

Modelo	Média qualidade (1–5)	Taxa de formato	Latência média (s)	Custo total	Falhas/recusas	Observação
A	2,94	25%	9,25	US\$ 0,000136	2 falhas; 0 recusas	Menor custo, porém baixa consistência e uma saída truncada. Qualidade intermediária;
B	3,38	25%	7,50	US\$ 0,005502	2 falhas de aderência; 0 recusas	excesso de conteúdo e invenções

C	4,55	75%	5,50	US\$ 0,010894	1 erro factual; 0 recusas	em P2/P4. Melhor qualidade e menor latência média; maior custo total.
---	------	-----	------	------------------	---------------------------------	--

Checkpoint — avance somente se:

- ☐ As médias foram calculadas com a mesma regra.
- ☐ A fonte de preços foi registrada.
- ☐ Latência e ocorrências estão consolidadas.

Passo 8 — Interpretar e recomendar

A recomendação deve considerar o projeto futuro, não apenas a maior média. Responda às perguntas abaixo no relatório:

- **Qual modelo apresentou melhor qualidade geral? Em quais tarefas?**

Resposta: O modelo C (Mistral Large) obteve a maior média, 4,55/5. Foi o melhor em P1, P2 e P4; em P3 entregou JSON válido e completo, mas inventou o ano 2024.

- **Qual modelo foi mais consistente na aderência aos formatos?**

Resposta: O modelo C, com 75% de aderência integral. Os modelos A e B atingiram 25% cada. O principal desvio de C foi a ausência da numeração explícita de 1 a 6 em P4.

- **Houve alucinações, omissões, JSON inválido, extrapolação ou recusa inadequada?**

Resposta: Sim. A inventou critérios de elegibilidade, assumiu 2023, gerou JSON inválido e truncou a FAQ. B assumiu 2023, informou o canal errado e acrescentou diversas regras. C inventou 2024 e fez pequenas inferências. Não houve recusas.

- **O ganho de qualidade justifica eventual aumento de custo ou latência?**

Resposta: Sim, neste teste. C custou US\$ 0,010894, mas teve a maior qualidade e também a menor latência média, 5,50 s. O custo absoluto foi baixo; em produção, a decisão deve ser refeita com volume real e preços atualizados.

- **Qual modelo é recomendado como principal? Para quais condições?**

Resposta: O modelo C é recomendado para geração corporativa quando fidelidade, clareza e aderência ao formato forem prioritárias. Datas, números e campos estruturados devem passar por validação automática ou revisão humana.

- **Qual modelo será a alternativa de contingência e por quê?**

Resposta: O modelo B é a contingência por alcançar a segunda maior média, 3,38/5, com latência de 7,50 s e custo inferior ao de C. Deve receber prompts mais restritivos e validação contra informações inventadas.

- **Quais limitações do experimento impedem uma conclusão definitiva?**

Resposta: Houve apenas uma execução por combinação, um único texto-base e avaliação manual. O ano foi omitido no texto, os parâmetros e a data do teste não

foram registrados, e as rotas dos provedores podem mudar. Também faltou medir repetibilidade e desempenho em maior escala.

Decisão	Modelo	Justificativa baseada em evidências	Ressalvas/condições
Principal	C - Mistral Large	Média 4,55/5, formato 75% e menor latência média (5,50 s).	Validar datas, números e JSON antes do uso corporativo.
Contingência	B - Aion-RP 1.0	Segunda maior média (3,38/5), custo menor que C e latência de 7,50 s.	Usar instruções mais restritivas e checagem contra extrapolações.
Não recomendado	A - Llama 3 8B Lunarix	Média 2,94/5, formato 25%, JSON inválido e FAQ truncada.	Somente para testes de baixo custo com validação forte e nova amostragem.

Checkpoint — avance somente se:

- ☐ A escolha cita resultados concretos.
- ☐ Custo e latência foram considerados.
- ☐ Há uma alternativa de contingência.
- ☐ As limitações do estudo foram declaradas.

Passo 9 — Conferir e organizar a entrega final

Estrutura sugerida do relatório

- 1. Identificação do grupo e objetivo do experimento.
- 2. Modelos, versões, acessos e parâmetros.
- 3. Texto-base, tarefas e prompts controlados.
- 4. Procedimento de execução e rubrica.
- 5. Resultados por tarefa e por modelo.
- 6. Custos, latência, falhas e limitações.
- 7. Recomendação do modelo principal e contingência.
- 8. Anexos: planilha, prompts, entradas e saídas brutas.

Checklist final de entrega

- Concluído** - o texto-base, os prompts, a rubrica e o procedimento estão documentados.
- Parcial** - nomes e rotas foram identificados; a data de execução não foi registrada.
- Concluído** - P1 a P4 aparecem preservados nas três séries de saídas.
- Concluído** - os 12 arquivos DOCX estão identificados por modelo e prompt na pasta do grupo.
- Concluído** - as seis notas, a ponderação e as médias foram preenchidas.
- Concluído** - os valores foram consolidados e as lacunas de coleta foram declaradas.
- Concluído** - a decisão usa média, formato, latência, custo e falhas observadas.
- Concluído** - o caso é fictício e não contém dados protegidos.
- Parcial** - os arquivos estão no pacote; a disponibilidade atual dos links externos não foi verificada.

Entrega concluída: o material produzido neste laboratório será reutilizado no Trabalho 2 para selecionar o modelo e justificar a criação do prompt baseline do Copiloto Inteligente Corporativo.